

Inteligência Artificial

Aprendizado de Máquina Supervisionado – Classificação: Árvore de Decisão, Naive Bayes, SVM, Métodos Ensemble e Critérios de Seleção de Algoritmos

Prof. Dr. Ivan Carlos Alcântara de Oliveira

<https://orcid.org/0000-0002-6020-7535>


Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão

- **Estrutura em forma de árvore** na qual cada nó interno corresponde a um teste de um atributo, cada ramo representa um resultado do teste e os nós folhas representam classes ou distribuições de classes.
- O nó mais elevado é conhecido como **raiz** e cada caminho da raiz até um nó folha corresponde à uma regra de classificação.

Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão – Exemplo para uma base de carros



Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão – Construção - O algoritmo de Hunt



- **A indução de uma árvore de decisão** pode ser expressa recursivamente:
 - **Selecione um atributo, coloque-o como raiz e faça uma ramificação para cada valor possível.**
 - **Repita o processo recursivamente para cada ramo, usando somente aqueles objetos que alcançam o ramo.**
 - **Se todos os objetos em um nó possuem a mesma classificação, pare de desenvolver essa parte da árvore.**

Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão

Atributo x_1

1o Nível da árvore





Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão

Atributos x_1 e x_2


2o Nível da árvore




Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão


3o Nível da árvore



4o Nível da Árvore



5o Nível da Árvore



Para cada nível seleciona-se um atributo diferente dos selecionados anteriormente no conjunto de dados

Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão – Construção – Algoritmo de Hunt

- Considere a base de dados comics.csv*

	Name	sex	smokes	tie	mask	cape	ears	class
0	Batman	male	no	no	yes	yes	yes	good
1	Robin	male	no	no	yes	yes	yes	good
2	Catwoman	female	no	no	yes	no	yes	bad
3	Joker	male	no	no	no	no	no	bad
4	Alfred	male	no	yes	no	no	no	good
5	Penguin	male	yes	yes	no	no	no	bad

Aprendizado Supervisionado


Algoritmos de Classificação – Árvore de decisão – Construção – Algoritmo de Hunt

- Considere a base de dados comics.csv pré-processada*


	Name	sex	smokes	tie	mask	cape	ears	class
0	Batman	1	0	0	1	1	1	good
1	Robin	1	0	0	1	1	1	good
2	Catwoman	0	0	0	1	0	1	bad
3	Joker	1	0	0	0	0	0	bad
4	Alfred	1	0	1	0	0	0	good
5	Penguin	1	1	1	0	0	0	bad

	Name	sex	smokes	tie	mask	cape	ears	class
0	Batman	1	0	0	1	1	1	good
1	Robin	1	0	0	1	1	1	good
2	Catwoman	0	0	0	1	0	1	bad
3	Joker	1	0	0	0	0	0	bad
4	Alfred	1	0	1	0	0	0	good
5	Penguin	1	1	1	0	0	0	bad

1. Escolha um atributo



2. Split dos valores





3. Mesma classe: Nó
Folha ou terminal

	Name	sex	smokes	tie	mask	cape	ears	class
0	Batman	1	0	0	1	1	1	good
1	Robin	1	0	0	1	1	1	good
2	Catwoman	0	0	0	1	0	1	bad
3	Joker	1	0	0	0	0	0	bad
4	Alfred	1	0	1	0	0	0	good
5	Penguin	1	1	1	0	0	0	bad

1. Escolha um atributo



2. Split dos valores



4. Diferentes
classes: Novos

Atributos -> 1. & 2.


3. Mesma classe: Nó
Folha ou terminal



	Name	sex	smokes	tie	mask	cape	ears	class
0	Batman	1	0	0	1	1	1	good
1	Robin	1	0	0	1	1	1	good
2	Catwoman	0	0	0	1	0	1	bad
3	Joker	1	0	0	0	0	0	bad
4	Alfred	1	0	1	0	0	0	good
5	Penguin	1	1	1	0	0	0	bad

1. Escolha um atributo

2. Split dos valores




4. Diferentes

classes: Novos

Atributos -> 1. & 2.

3. Mesma classe: Nó

Folha ou terminal



Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão - Construção

- **No exemplo fizemos escolhas arbitrárias dos atributos para a construção da árvore.**
- **Escolha de outros atributos ou em uma ordem diferentes chegaríamos a outras árvores de decisão** que poderíamos igualmente empregar para a classificação dos dados.

Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão - Construção

- Os algoritmos de Árvore de Decisão constroem as Árvores do mesmo modo recursivo que construímos aqui.
- Todos eles buscam particionamentos que maximizem a decisão, tornando a Árvores e os caminhos que temos que percorrer menores.
- Eles **buscam a cada nível da Árvore (partição) uma maior informação para “pureza” das partições dos dados em termos de sua classe.**

Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão - Construção

- Diferentes **algoritmos de Árvores de Decisão** e seus **critérios para seleção dos nós**:
 - **ID3 *algorithm*** (*Claude Shannon Entropy*): Ganho de Informação
 - **C4.5 algorithm**: *Gain ratio*
 - **CART algorithm**: *Gini index*
- Seja qual for o método empregado a ideia é a mesma.

Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão - Construção

- **Qual atributo escolher para a divisão? Qual nó escolher para expansão?**

Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão - Construção

- É preciso definir uma medida de pureza de cada nó e expandir aquele nó com filhos mais puros.
- A medida de pureza a ser utilizada é “**informação**” que representa a **quantidade esperada de conhecimento necessário para especificar se um novo objeto deverá ser classificado em determinada classe, dado que o objeto atingiu aquele nó folha.**

	Name	sex	smokes	tie	mask	cape	ears	class
0	Batman	1	0	0	1	1	1	good
1	Robin	1	0	0	1	1	1	good
2	Catwoman	0	0	0	1	0	1	bad
3	Joker	1	0	0	0	0	0	bad
4	Alfred	1	0	1	0	0	0	good
5	Penguin	1	1	1	0	0	0	bad


1. Escolha um atributo

2. Split dos valores




4. Diferentes
classes: Novos

Atributos -> 1. & 2.



3. Mesma classe: Nó
Folha ou terminal



Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de decisão - Construção

- O **algoritmo calcula o ganho de informação para cada atributo**, e **aquele com maior ganho é escolhido** como o atributo teste para o conjunto X .
- Um **nó da árvore é criado e rotulado como esse atributo**.
- **Ramos são criados para cada valor do atributo e os objetos são particionados**.

Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros – com valores nominais para os atributos

Compra	Manutenção	Portas	Passageiros	Bagageiro	Segurança	Aceitabilidade
muito alto	muito alto	2	mais	pequeno	baixa	inaceitável
muito alto	baixo	3	4	pequeno	baixa	inaceitável
muito alto	médio	4	mais	grande	média	aceitável
muito alto	baixo	5	mais	médio	média	aceitável
médio	baixo	3	4	pequeno	alta	bom
baixo	médio	2	4	pequeno	alta	bom
médio	médio	2	4	grande	alta	ótimo
médio	baixo	4	mais	grande	alta	ótimo

Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros

- O primeiro passo é determinar o ganho de informação para cada atributo com relação ao atributo classe.
- A informação esperada para o atributo classe **Aceitabilidade** para a amostra é igual a 2,000, ou seja,

$$I(C_1, C_2, C_3, C_4) = 2,000$$

- Onde C_1 = inaceitável, C_2 = aceitável, C_3 = bom e C_4 = ótimo.

Aprendizado Supervisionado


Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros

- O valor do ganho de informação e entropia (inverso do ganho) para a definição do primeiro nó adicionado à árvore de decisão é dado pela tabela abaixo.

	Compra	Manutenção	Portas	Passageiros	Bagageiro	Segurança
Entropia	0,844	1,594	1,094	1,5	0,844	0,5
Ganho	1,156	0,406	0,906	0,5	1,156	1,5

- O atributo Segurança é selecionado como raiz devido seu melhor valor para o Ganho.
- Para realizar a expansão do nó Segurança, é necessário decidir se para cada valor distinto será criado um novo nó ou uma folha.

Compra	Manutenção	Portas	Passageiros	Bagageiro	Segurança	Aceitabilidade
muito alto	muito alto	2	mais	pequeno	baixa	inaceitável
muito alto	baixo	3	4	pequeno	baixa	inaceitável
muito alto	médio	4	mais	grande	média	aceitável
muito alto	baixo	5	mais	médio	média	aceitável
médio	baixo	3	4	pequeno	alta	bom
baixo	médio	2	4	pequeno	alta	bom
médio	médio	2	4	grande	alta	ótimo
médio	baixo	4	mais	grande	alta	ótimo



Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros


- Para **expansão do nó Segurança em relação ao valor baixa** são **utilizados apenas os objetos que possuem esse valor no atributo Segurança**.

Compra	Manutenção	Portas	Passageiros	Bagageiro	Segurança	Aceitabilidade
muito alto	muito alto	2	mais	pequeno	baixa	inaceitável
muito alto	baixo	3	4	pequeno	baixa	inaceitável
muito alto	médio	4	mais	grande	média	aceitável
muito alto	baixo	5	mais	médio	média	aceitável
médio	baixo	3	4	pequeno	alta	bom
baixo	médio	2	4	pequeno	alta	bom
médio	médio	2	4	grande	alta	ótimo
médio	baixo	4	mais	grande	alta	ótimo

- Observe que **Segurança “baixa” = Aceitabilidade “inaceitável”**.

Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros



Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros


- Utilizando a mesma regra para o valor média.

Compra	Manutenção	Portas	Passageiros	Bagageiro	Segurança	Aceitabilidade
muito alto	muito alto	2	mais	pequeno	baixa	inaceitável
muito alto	baixo	3	4	pequeno	baixa	inaceitável
muito alto	médio	4	mais	grande	média	aceitável
muito alto	baixo	5	mais	médio	média	aceitável
médio	baixo	3	4	pequeno	alta	bom
baixo	médio	2	4	pequeno	alta	bom
médio	médio	2	4	grande	alta	ótimo
médio	baixo	4	mais	grande	alta	ótimo

- Observe que Segurança “média” = Aceitabilidade “aceitável”.

Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros



Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros

- Para o **atributo Segurança com o valor alta** considera-se apenas os objetos com valor alta para o atributo Segurança, sendo que **o próprio atributo é removido do processo de decisão**.

Compra	Manutenção	Portas	Passageiros	Bagageiro	Aceitabilidade
médio	baixo	3	4	pequeno	bom
baixo	médio	2	4	pequeno	bom
médio	médio	2	4	grande	ótimo
médio	baixo	4	mais	grande	ótimo

Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros

- Determinando o **ganho de informação** para cada atributo em **relação ao atributo classe**.
- A **informação esperada** para o atributo **Aceitabilidade** para a amostra é igual a 1,000, ou seja,

$$I(C_1, C_2, C_3, C_4) = 1,000$$

- O valor de entropia e ganho de informação para todos os atributos são:

	Compra	Manutenção	Portas	Passageiros	Bagageiro
Entropia	0,689	1	0,5	0,689	0
Ganho	0,311	0	0,5	0,311	1

- O atributo Bagageiro possui o maior ganho de informação, é o escolhido para o nó da árvore.

Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros


- O atributo **Bagageiro** possui dois valores : **pequeno** e **grande**.

Compra	Manutenção	Portas	Passageiros	Bagageiro	Aceitabilidade
médio	baixo	3	4	pequeno	bom
baixo	médio	2	4	pequeno	bom
médio	médio	2	4	grande	ótimo
médio	baixo	4	mais	grande	ótimo

- Será necessário decidir se **para cada valor distinto será criado um novo nó ou uma folha**.
- Observa-se que o atributo Aceitabilidade **possui apenas um valor “bom”**. Portanto, é adicionada como folha.
- A mesma situação **ocorre com o valor “grande”**, o que levará à adição de uma folha referente ao **valor “ótimo”**.

Aprendizado Supervisionado

Algoritmos de Classificação – Algoritmo de Indução de Árvores de Decisão –
Exemplo – Base de Dados - Carros – Árvore Concluída



Aprendizado Supervisionado

Algoritmos de Classificação – Árvore de Decisão – Poda

- **Poda:** A técnica de reduzir a profundidade da Árvore de Decisão é chamada de Poda e permite reduzir o ***overfitting*** (sobreajuste) dos modelos, um problema geralmente encontrado em Árvores de Decisão.

Aprendizado Supervisionado

Algoritmos de Classificação –de Decisão – Informação mútua e Seleção de Atributos

- O ganho de informação **fornece um meio de avaliarmos atributos que são potencialmente mais preditores que outros.**
- As **classes do `sklearn.feature_selection`** que se baseiam em testes estatísticos univariados e pode incluir a informação mútua **podem ser usadas para seleção de atributos e redução de dimensionalidade em conjuntos de amostras são:**
 - **SelectKBest, SelectPercentile e GenericUnivariateSelect**

Aprendizado Supervisionado

Algoritmos de Classificação –de Decisão – Seleção de Atributos

Outras formas para seleção de atributos são:

- **Eliminação recursiva de atributos (RFE):** faz uso da acurácia do modelo para identificar os atributos que mais contribuem para prever a variável alvo.
- **Método Ensemble (por ex.: Random Forest):** podem ser usados para estimar a importância de cada atributo, retornando um score para cada atributo. Quanto maior esse score, maior a importância do atributo.

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes

- Classificadores bayesianos são **classificadores estatísticos fundamentados no Teorema de Bayes** (e usado para **predizer a probabilidade de pertinência de um objeto a determinada classe**).
- Possui **desempenho comparável a redes neurais artificiais e árvores de decisão para alguns problemas**.
- Apresenta **alta acurácia e velocidade de processamento quanto aplicados a grandes bases de dados**.

Aprendizado Supervisionado

Algoritmo - Naïve Bayes

- **É um algoritmo probabilístico baseado no teorema de Bayes.**

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

- **Assumem que o efeito do valor de um atributo em uma dada classe é independente dos valores dos outros atributos.**

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes - Exemplo

- Utilizando a base de dados Carros:

<https://archive.ics.uci.edu/dataset/19/car+evaluation>

- [**Knowledge acquisition and explanation for multi-attribute decision making**](#) By M. Bohanec, V. Rajkovič. 1988.
Published in 8th Intl Workshop on Expert Systems and their Applications, Avignon, France

- 1728 carros
- 7 atributos, sendo 6 de entrada e 1 alvo (Classe).

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes - Exemplo

Nome do Atributo	Papel	Tipo	Descrição	Valores
buying	Característica (Entrada)	Categórico	Preço de compra	vhigh, high, med, low
maint	Característica (Entrada)	Categórico	Preço de manutenção	vhigh, high, med, low
doors	Característica (Entrada)	Categórico	Número de Portas	2, 3, 4, 5more
persons	Característica (Entrada)	Categórico	Passageiros	2, 4, more
lug_boot	Característica (Entrada)	Categórico	Bagageiro	small, med, big,
safety	Característica (Entrada)	Categórico	Segurança	low, med, high
class	Alvo	Categórico	Aceitabilidade	unacc, acc, good, vgood

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes - Exemplo

Nome do Atributo	Papel	Tipo	Descrição	Valores
buying	Característica (Entrada)	Categórico	Preço de compra	vhigh = 1, high = 2, med = 3, low = 4
maint	Característica (Entrada)	Categórico	Preço de manutenção	vhigh = 1, high = 2, med = 3, low = 4
doors	Característica (Entrada)	Categórico	Número de Portas	2, 3, 4, 5more = 5
persons	Característica (Entrada)	Categórico	Passageiros	2, 4, more = 6
lug_boot	Característica (Entrada)	Categórico	Bagageiro	small = 1, med = 2, big = 3,
safety	Característica (Entrada)	Categórico	Segurança	low = 1, med = 2, high = 3
class	Alvo	Categórico	Aceitabilidade	unacc = 1, acc = 2, good = 3, vgood = 4

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes

- **O conceito de independência condicional de classe (ICC) considerando a base de dados Carro, a aceitabilidade do carro depende:**
 - preço de compra,
 - preço de manutenção,
 - número de portas,
 - quantidade de passageiros,
 - tamanho do bagageiro e
 - segurança.
- **A ICC do naïve Bayes assume que cada um desses fatores contribui de forma independente dos demais para a aceitabilidade final.**

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes – Teorema de Bayes

- Em **problemas de classificação**, o **objetivo é determinar a probabilidade $P(H|x)$** , ou seja, a probabilidade de que a hipótese H seja satisfeita dada o objeto observado x .
- **$P(H|x)$ é a probabilidade a posteriori de H dado x e**
- **$P(H)$ é probabilidade a priori de H .**

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes – Teorema de Bayes

- As probabilidades **$P(x)$, $P(H)$ e $P(x|H)$** são **estimativas** para a base de dados em um estudo.
- A utilidade do **Teorema de Bayes** reside no fato de que **ele fornece uma maneira de calcular a probabilidade a posteriori , $P(H|x)$** , a partir de $P(x)$, $P(H)$ e $P(x|H)$:

$$P(H|x) = \frac{P(x|H)P(H)}{P(x)}$$

- Como **$P(x)$** é constante para todas as classes **$H = C_i$** , somente **$P(x|C_i) P(C_i)$** precisa ser maximizado.

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes – Construção

- **Dado um objeto x com classe desconhecida.**
- O classificador deve ser usado para **predizer a classe à qual esse objeto pertence com base na maior probabilidade a posteriori encontrada**, dado x .
- O classificador bayesiano determina uma **classe C_i para o objeto x** se, somente se:

$$P(C_i|x) > P(C_j|x), \forall j \neq i.$$

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes – Exemplo

- Como exemplo, suponha a base de dados Carros.
- Consideremos as **probabilidades para cada classe** sendo $P(\text{inaceitável}) = 0,700$, $P(\text{aceitável}) = 0,222$, $P(\text{bom}) = 0,040$ e $P(\text{ótimo}) = 0,038$.
- O objetivo é **classificar o objeto x** descrito pelos **atributos: compra = médio, manutenção = médio, portas = 4, passageiros = 4, bagageiro = médio e segurança = média**.
- E consideremos também como entrada a **matriz de probabilidades na tabela a seguir**.

Atributo	Valor	Classe			
		inaceitável	aceitável	bom	ótimo
Compra	muito alto	0,298	0,188	0,000	0,000
Compra	alto	0,268	0,281	0,000	0,000
Compra	médio	0,221	0,299	0,333	0,400
Compra	baixo	0,213	0,232	0,667	0,600
Manutenção	muito alto	0,298	0,188	0,000	0,000
Manutenção	alto	0,260	0,273	0,000	0,200
Manutenção	médio	0,221	0,299	0,333	0,400
Manutenção	baixo	0,221	0,240	0,667	0,400
Portas	2	0,269	0,211	0,217	0,153
Portas	3	0,248	0,258	0,261	0,231
Portas	4	0,241	0,266	0,261	0,308
Portas	5mais	0,241	0,266	0,261	0,308
Passageiros	2	0,476	0,000	0,000	0,000
Passageiros	4	0,258	0,516	0,522	0,462
Passageiros	mais	0,266	0,484	0,478	0,538
Bagageiro	pequeno	0,372	0,273	0,304	0,000
Bagageiro	médio	0,324	0,352	0,348	0,385
Bagageiro	grande	0,304	0,375	0,348	0,615
Segurança	baixa	0,476	0,000	0,000	0,000
Segurança	média	0,295	0,469	0,565	0,000
Segurança	alta	0,229	0,531	0,435	1,000

compra = médio,

Atributo	Valor	Classe			
		inaceitável	aceitável	bom	ótimo
Compra	muito alto	0,298	0,188	0,000	0,000
Compra	alto	0,268	0,281	0,000	0,000
Compra	médio	0,221	0,299	0,333	0,400
Compra	baixo	0,213	0,232	0,667	0,600
Manutenção	muito alto	0,298	0,188	0,000	0,000
Manutenção	alto	0,260	0,273	0,000	0,200
Manutenção	médio	0,221	0,299	0,333	0,400
Manutenção	baixo	0,221	0,240	0,667	0,400
Portas	2	0,269	0,211	0,217	0,153
Portas	3	0,248	0,258	0,261	0,231
Portas	4	0,241	0,266	0,261	0,308
Portas	5mais	0,241	0,266	0,261	0,308
Passageiros	2	0,476	0,000	0,000	0,000
Passageiros	4	0,258	0,516	0,522	0,462
Passageiros	mais	0,266	0,484	0,478	0,538
Bagageiro	pequeno	0,372	0,273	0,304	0,000
Bagageiro	médio	0,324	0,352	0,348	0,385
Bagageiro	grande	0,304	0,375	0,348	0,615
Segurança	baixa	0,476	0,000	0,000	0,000
Segurança	média	0,295	0,469	0,565	0,000
Segurança	alta	0,229	0,531	0,435	1,000

compra = médio,
manutenção = médio,

Atributo	Valor	Classe			
		inaceitável	aceitável	bom	ótimo
Compra	muito alto	0,298	0,188	0,000	0,000
Compra	alto	0,268	0,281	0,000	0,000
Compra	médio	0,221	0,299	0,333	0,400
Compra	baixo	0,213	0,232	0,667	0,600
Manutenção	muito alto	0,298	0,188	0,000	0,000
Manutenção	alto	0,260	0,273	0,000	0,200
Manutenção	médio	0,221	0,299	0,333	0,400
Manutenção	baixo	0,221	0,240	0,667	0,400
Portas	2	0,269	0,211	0,217	0,153
Portas	3	0,248	0,258	0,261	0,231
Portas	4	0,241	0,266	0,261	0,308
Portas	5mais	0,241	0,266	0,261	0,308
Passageiros	2	0,476	0,000	0,000	0,000
Passageiros	4	0,258	0,516	0,522	0,462
Passageiros	mais	0,266	0,484	0,478	0,538
Bagageiro	pequeno	0,372	0,273	0,304	0,000
Bagageiro	médio	0,324	0,352	0,348	0,385
Bagageiro	grande	0,304	0,375	0,348	0,615
Segurança	baixa	0,476	0,000	0,000	0,000
Segurança	média	0,295	0,469	0,565	0,000
Segurança	alta	0,229	0,531	0,435	1,000

compra = médio,
manutenção = médio,
portas = 4,

Atributo	Valor	Classe			
		inaceitável	aceitável	bom	ótimo
Compra	muito alto	0,298	0,188	0,000	0,000
Compra	alto	0,268	0,281	0,000	0,000
Compra	médio	0,221	0,299	0,333	0,400
Compra	baixo	0,213	0,232	0,667	0,600
Manutenção	muito alto	0,298	0,188	0,000	0,000
Manutenção	alto	0,260	0,273	0,000	0,200
Manutenção	médio	0,221	0,299	0,333	0,400
Manutenção	baixo	0,221	0,240	0,667	0,400
Portas	2	0,269	0,211	0,217	0,153
Portas	3	0,248	0,258	0,261	0,231
Portas	4	0,241	0,266	0,261	0,308
Portas	5mais	0,241	0,266	0,261	0,308
Passageiros	2	0,476	0,000	0,000	0,000
Passageiros	4	0,258	0,516	0,522	0,462
Passageiros	mais	0,266	0,484	0,478	0,538
Bagageiro	pequeno	0,372	0,273	0,304	0,000
Bagageiro	médio	0,324	0,352	0,348	0,385
Bagageiro	grande	0,304	0,375	0,348	0,615
Segurança	baixa	0,476	0,000	0,000	0,000
Segurança	média	0,295	0,469	0,565	0,000
Segurança	alta	0,229	0,531	0,435	1,000

compra = médio,
 manutenção = médio,
 portas = 4,
 passageiros = 4,

Atributo	Valor	Classe			
		inaceitável	aceitável	bom	ótimo
Compra	muito alto	0,298	0,188	0,000	0,000
Compra	alto	0,268	0,281	0,000	0,000
Compra	médio	0,221	0,299	0,333	0,400
Compra	baixo	0,213	0,232	0,667	0,600
Manutenção	muito alto	0,298	0,188	0,000	0,000
Manutenção	alto	0,260	0,273	0,000	0,200
Manutenção	médio	0,221	0,299	0,333	0,400
Manutenção	baixo	0,221	0,240	0,667	0,400
Portas	2	0,269	0,211	0,217	0,153
Portas	3	0,248	0,258	0,261	0,231
Portas	4	0,241	0,266	0,261	0,308
Portas	5mais	0,241	0,266	0,261	0,308
Passageiros	2	0,476	0,000	0,000	0,000
Passageiros	4	0,258	0,516	0,522	0,462
Passageiros	mais	0,266	0,484	0,478	0,538
Bagageiro	pequeno	0,372	0,273	0,304	0,000
Bagageiro	médio	0,324	0,352	0,348	0,385
Bagageiro	grande	0,304	0,375	0,348	0,615
Segurança	baixa	0,476	0,000	0,000	0,000
Segurança	média	0,295	0,469	0,565	0,000
Segurança	alta	0,229	0,531	0,435	1,000

compra = médio,
 manutenção = médio,
 portas = 4,
 passageiros = 4,
 bagageiro = médio

Atributo	Valor	Classe			
		inaceitável	aceitável	bom	ótimo
Compra	muito alto	0,298	0,188	0,000	0,000
Compra	alto	0,268	0,281	0,000	0,000
Compra	médio	0,221	0,299	0,333	0,400
Compra	baixo	0,213	0,232	0,667	0,600
Manutenção	muito alto	0,298	0,188	0,000	0,000
Manutenção	alto	0,260	0,273	0,000	0,200
Manutenção	médio	0,221	0,299	0,333	0,400
Manutenção	baixo	0,221	0,240	0,667	0,400
Portas	2	0,269	0,211	0,217	0,153
Portas	3	0,248	0,258	0,261	0,231
Portas	4	0,241	0,266	0,261	0,308
Portas	5mais	0,241	0,266	0,261	0,308
Passageiros	2	0,476	0,000	0,000	0,000
Passageiros	4	0,258	0,516	0,522	0,462
Passageiros	mais	0,266	0,484	0,478	0,538
Bagageiro	pequeno	0,372	0,273	0,304	0,000
Bagageiro	médio	0,324	0,352	0,348	0,385
Bagageiro	grande	0,304	0,375	0,348	0,615
Segurança	baixa	0,476	0,000	0,000	0,000
Segurança	média	0,295	0,469	0,565	0,000
Segurança	alta	0,229	0,531	0,435	1,000

compra = médio,
manutenção = médio,
portas = 4,
passageiros = 4,
bagageiro = médio e
segurança = média.

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes – Exemplo

- Partindo dos dados de entrada, o algoritmo calcula a probabilidade de o objeto x pertencer a cada classe:
 - $P(\text{inaceitável}/x) = P(x/\text{inaceitável}) \times P(\text{inaceitável})$
 - $P(\text{aceitável}/x) = P(x/\text{aceitável}) \times P(\text{aceitável})$
 - $P(\text{bom}/x) = P(x/\text{bom}) \times P(\text{bom})$
 - $P(\text{ótimo}/x) = P(x/\text{ótimo}) \times P(\text{ótimo})$
- Lembrando: $P(\text{inaceitável}) = 0,700$, $P(\text{aceitável}) = 0,222$, $P(\text{bom}) = 0,040$ e $P(\text{ótimo}) = 0,038$

Atributo	Valor	Classe			
		inaceitável	aceitável	bom	ótimo
Compra	muito alto	0,298	0,188	0,000	0,000
Compra	alto	0,268	0,281	0,000	0,000
Compra	médio	0,221	0,299	0,333	0,400
Compra	baixo	0,213	0,232	0,667	0,600
Manutenção	muito alto	0,298	0,188	0,000	0,000
Manutenção	alto	0,260	0,273	0,000	0,200
Manutenção	médio	0,221	0,299	0,333	0,400
Manutenção	baixo	0,221	0,240	0,667	0,400
Portas	2	0,269	0,211	0,217	0,153
Portas	3	0,248	0,258	0,261	0,231
Portas	4	0,241	0,266	0,261	0,308
Portas	5mais	0,241	0,266	0,261	0,308
Passageiros	2	0,476	0,000	0,000	0,000
Passageiros	4	0,258	0,516	0,522	0,462
Passageiros	mais	0,266	0,484	0,478	0,538
Bagageiro	pequeno	0,372	0,273	0,304	0,000
Bagageiro	médio	0,324	0,352	0,348	0,385
Bagageiro	grande	0,304	0,375	0,348	0,615
Segurança	baixa	0,476	0,000	0,000	0,000
Segurança	média	0,295	0,469	0,565	0,000
Segurança	alta	0,229	0,531	0,435	1,000

$$P(\text{inaceitável}/x) = \\ P(x/\text{inaceitável}) \times \\ P(\text{inaceitável})$$

$$P(\text{inaceitável}/x) = \\ P(x/\text{inaceitável}) \times 0,700$$

$$P(\text{inaceitável}/x) = \\ (0,221 \times 0,221 \times 0,241 \times 0,258 \times \\ 0,324 \times 0,295) \times 0,700$$

$$P(\text{inaceitável}/x) = \\ 2,04 \times 10^{-4}$$

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes – Exemplo

- Partindo dos dados de entrada, o algoritmo calcula a probabilidade de o objeto x pertencer a cada classe:

$$\begin{aligned} &P(x|inaceitável) \times P(inaceitável) \\ &= \left(\frac{0,221 \times 0,221 \times 0,241 \times 0,258}{0,324 \times 0,295} \right) \times 0,700 \\ &= 2,04 \times 10^{-4} \end{aligned}$$

$$\begin{aligned} &P(x|aceitável) \times P(aceitável) \\ &= \left(\frac{0,299 \times 0,229 \times 0,266 \times 0,516}{0,352 \times 0,469} \right) \times 0,222 \\ &= 4,5 \times 10^{-4} \end{aligned}$$

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes – Exemplo

- Partindo dos dados de entrada o algoritmo calcula a probabilidade de o objeto x pertencer a cada classe:

$$\begin{aligned} &P(x|bom) \times P(bom) \\ &= \left(\begin{array}{c} 0,333 \times 0,333 \times 0,261 \times 0,522 \times \\ 0,348 \times 0,565 \end{array} \right) \times 0,040 \\ &= 1,19 \times 10^{-4} \end{aligned}$$

$$\begin{aligned} &P(x|ótimo) \times P(ótimo) \\ &= \left(\begin{array}{c} 0,4 \times 0,4 \times 0,308 \times 0,462 \times \\ 0,385 \times 0,0 \end{array} \right) \times 0,038 \\ &= 0,000 \end{aligned}$$

Aprendizado Supervisionado

Algoritmos de Classificação – Classificador naïve Bayes – Exemplo

- Para **determinar a classe do objeto x, basta encontrar a probabilidade máxima dada pelo algoritmo, que é $4,50 \times 10^{-4}$ para a classe aceitável.**

Aprendizado Supervisionado

Algoritmo - Naïve Bayes - Aplicações

- **Previsão em tempo real:** Naive Bayes é um classificador de aprendizagem rápido.
- **Classificação de texto:** devido ao melhor resultado em problemas multiclasse e regra de independência têm alta taxa de sucesso em comparação a outros algoritmos.
- **Sistema de recomendação:** Naive Bayes e a filtragem colaborativa juntos criam um sistema de recomendação que usa técnicas de aprendizado de máquina e mineração de dados para filtrar informações invisíveis e prever se um usuário gostaria de um determinado recurso ou não.

Aprendizado Supervisionado


Algoritmo - Máquinas de Vetores de Suporte (*Support Vector Machines* - SVMs)

- As **SVMs** pertence a categoria de algoritmos baseada em **otimização**.
- A SVM é uma **técnica de aprendizado estatístico**, baseada no princípio da Minimização do Risco Estrutural (SEM) e **pode ser usada para resolver problemas de classificação e regressão**.
- O treinamento das SVMs **tem como objetivo maximizar a margem de separação entre os objetos de diferentes classes**.

Aprendizado Supervisionado

Algoritmo - Máquinas de Vetores de Suporte (SVMs) - Funcionamento


- Na figura temos a linha verde tracejada (representa o hiperplano) – uma linha que separa as duas classes.



Aprendizado Supervisionado

Algoritmo - Máquinas de Vetores de Suporte (SVMs) - Funcionamento


- Os pontos de dados que representam a classe vermelha e os pontos de dados que representam a classe azul.



Aprendizado Supervisionado

Algoritmo - Máquinas de Vetores de Suporte (SVMs) - Funcionamento


- Para **encontrar o hiperplano é necessário calcular as margens de cada classe (margem máxima).**



Aprendizado Supervisionado

Algoritmo - Máquinas de Vetores de Suporte (SVMs) - Funcionamento


- Esses **elementos que estão na margem** são chamados de **vetores de suporte** ou apenas pontos críticos.
- Os dados devem estar normalizados para obter melhores resultados.



Aprendizado Supervisionado

Algoritmo - Máquinas de Vetores de Suporte (SVMs) - Funcionamento

- O algoritmo faz:
 - 1) Verifica se os dados são linearmente separáveis;




Espaço Original

Aprendizado Supervisionado

Algoritmo - Máquinas de Vetores de Suporte (SVMs) - Funcionamento

- O algoritmo faz:
 - 1) Verifica se os dados são linearmente separáveis;
 - 2) Caso não haja uma separação linear, então, aumento a dimensão (crio uma nova dimensão).
 - 3) E então, passo a ter os dados linearmente separáveis.
 - 4) A partir daí, os vetores de suporte são encontrados.
 - 5) Então, conseguimos encontrar o hiperplano (linha exatamente no meio dos dados).




Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble

- É um **grupo de algoritmos de aprendizado de máquina treinados em paralelo, unindo ao final os resultados obtidos.**
- **Ensemble:** palavra francesa que significa **conjunto - grupo.**
- Em geral, requer um pouco mais de capacidade computacional, mas **consegue obter uma precisão muito alta.**

Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble



- Os dados de treino são utilizados para alimentar quatro modelos de maneira simultânea.
- Então, no final, é possível calcular: a média, votação, fazer com que um modelo corrija o erro do outro, são várias técnicas dentro dos métodos ensemble.

Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble - Exemplo

- Abordagens principais:
- ***Bootstrap Aggregation*** ou ***Bagging***
- ***Boosting***
- ***Votação***

Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble – **Abordagens Principais - *Bagging***

- ***Bootstrap Aggregation* ou *Bagging***: é uma técnica que faz uso de algoritmos do mesmo tipo em paralelo para criar modelos diferentes. Por exemplo, árvores de decisão em paralelo.
- **Algoritmos exemplo:**
 - Bagged CART (*Classification and Regression Trees*);
 - Random Forest.


Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble - ***Random Forest*** (Floresta Aleatória)

- Usa **vários algoritmos de árvore de decisão considerados fracos que quando combinados torna-se poderoso.**
- Os vários algoritmos **trabalham entre si para encontrar o melhor caminho para a saída e no final é realizada uma votação (classificação) ou média (regressão) para obter o melhor valor entre os algoritmos que atuaram em paralelo.**
- **É um dos mais precisos em aprendizado de máquina.**
- **É utilizado para a seleção de variáveis e criação do modelo preditivo.**

Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble - **Random Forest** (Floresta Aleatória) – Classificação – Exemplo



Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble - *Random Forest* (Floresta Aleatória) – Prós e Contras (1)

- **Prós:**
 - É poderoso e preciso.
 - Tem um ótimo desempenho em muitos problemas, incluindo atributos (variáveis) com relacionamentos não lineares.
 - Hiperparâmetros fáceis de entender e não são muitos.
- **Contras:**
 - Não muito fáceis de interpretar estatisticamente.
 - *Overfitting* pode facilmente ocorrer.

Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble – **Abordagens Principais - *Boosting***

- ***Boosting***: é uma técnica que faz uso de algoritmos do mesmo tipo, porém cada modelo tenta corrigir os erros do modelo anterior.
- É mais ou menos como se fosse uma linha de produção (modelos sequenciais), ou seja, um **algoritmo é treinado e gera o modelo**.
- **Esse modelo vai ter uma taxa de erros. Essa taxa de erros vai ser corrigida pelo próximo algoritmo.**
- **Que então, vai ser treinado, criar um outro modelo e então obter outra taxa de erros, na qual espera-se seja menor.**
- **Isso vai alimentar um outro algoritmo que segue o mesmo procedimento descrito anteriormente.**

Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble – **Abordagens Principais - *Boosting***

- Assim, no final, **o modelo obtido é aquele que foi corrigindo os erros dos modelos anteriores.**
- **Para isso funcionar todos os algoritmos tem que ser do mesmo tipo.**
- **O tempo de treinamento é bem maior e em geral a capacidade computacional também.**
- **Exemplos:**
 - C5.0
 - *Stochastic Gradient Boosting* (GBM)
 - *eXtreme Gradient Boosting* (XGBoost)
 - **AdaBoost.**


Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble - **AdaBoost**

- Utiliza a **abordagem do tipo boosting**, ou seja, faz uso de **algoritmos do mesmo tipo (por exemplo, árvores de decisão do tipo CART)**, porém cada modelo gerado tenta corrigir os erros do modelo anterior.
- Em geral, **requer um pouco mais de capacidade computacional, mas consegue obter uma precisão muito alta.**
- **Pode ser utilizado para classificação ou regressão.**

Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble - **AdaBoost** – Funcionamento (1)



Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble - **AdaBoost**

Prós

1. Corrige iterativamente os erros do classificador fraco e melhora a precisão combinando estimadores fracos.
2. Não é propenso a *overfitting*.

Contras

1. É sensível a dados de ruído.
2. É altamente afetado por *outliers* (valores extremos) porque tenta ajustar cada ponto perfeitamente.
3. AdaBoost é mais lento em comparação com XGBoost.

Aprendizado Supervisionado

Algoritmo - Métodos do tipo ensemble – **Abordagens Principais - Votação**

- **Votação:** quando é feito o uso de **algoritmos diferentes treinados em paralelo e ao final faz-se uma votação para escolher qual daqueles algoritmos apresentou um modelo com melhor desempenho.**
- **Exemplos:**
 - *Coombs' method*
 - *Boyer–Moore majority vote algorithm*
 - *Nanson's method*

Aprendizado Supervisionado

Algoritmo - **Fatores a considerar na escolha do algoritmo ideal**



Precisão

Tipo de Problema a
ser Resolvido



Tempo de Treinamento

Linearidade



Número de Recursos

Número de Parâmetros



Aprendizado Supervisionado

Algoritmo - Fatores a considerar na escolha do algoritmo ideal

- **Precisão:** é desejável um algoritmo que acerte na maioria das vezes, ou seja, maior precisão. Mas, **melhor precisão, pode gerar *overffiting*** (aprende demais - sobreajustamento), por exemplo, se o **conjunto de dados for muito pequeno**.
- **Tipo de Problema:** Classificação , Regressão, Clusterização, etc.
- **Tempo de treinamento:** deve ser definido o tempo disponível para gerar um resultado aceitável.
Por exemplo, dependendo do conjunto de dados pode levar duas semanas, algoritmos complexos.
Google realizou um treinamento de PLN (Processamento de Linguagem Natural) com 1 trilhão de registros e levou 3 semanas.
Neste caso, podem ser necessárias milhares de máquinas para processar e armazenar os dados.
- **Linearidade:** os dados podem ser linearmente separáveis ou não.

Aprendizado Supervisionado

Algoritmo - Fatores a considerar na escolha do algoritmo ideal

- **Números de parâmetros:** cada algoritmo tem uma série de parâmetros (hiperparâmetros) a sua disposição. É necessário verificar até que ponto isso pode complicar ou aumentar o tempo de treinamento do modelo, consequentemente o tempo do projeto.
- **Número de recursos:** número de variáveis ou atributos no seu conjunto de dados (ex.: colunas numa planilha do Excel).
Por exemplo, *dataset* com 400 variáveis (atributos preditores), talvez seja necessário fazer uma redução da dimensionalidade, utilizando, por exemplo, o algoritmo PCA (*Principal Components Analysis*).
Pode-se usar um algoritmo para seleção de variáveis, depois um algoritmo para treinar o modelo final. Ou, pode-se usar um algoritmo para redução da dimensionalidade, depois um algoritmo para treinar o modelo final, e assim por diante.
Então, o número de variáveis também impacta na escolha do melhor algoritmo.

Aprendizado Supervisionado

Algoritmo - Comparação entre os principais algoritmos - Classificação binária (2 classes possíveis).

Algoritmo	Tempo de Treinamento	Precisão	Linearidade
Regressão Logística			
Árvore de Decisão			N/A
Random Forest			N/A
Redes Neurais			N/A
SVM			
Métodos Bayesianos			



Alto



Moderado

Aprendizado Supervisionado

Algoritmo - Comparação entre os principais algoritmos - Classificação multiclasse (mais de 2 classes possíveis).



Algoritmo	Tempo de Treinamento	Precisão	Linearidade
Regressão Logística			
Árvore de Decisão			N/A
Random Forest			N/A
Redes Neurais			N/A
SVM			

Bibliografia

BÁSICA:

- AGGARWAL, Charu C. **Artificial Intelligence: A Textbook**. New York: Springer: 2021.
- CHOLLET, François. **Deep Learning with Python, 2ed**. Shelter Island: Manning, 2021.
- GÉRON, Aurélien. **Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**, 2 ed. Sebastopol: O'Reilly, 2019.

COMPLEMENTAR:

- GOODFELLOW, Ian; BENGIO, Yoshua, COURVILLE, Aaron. **Deep Learning**. Cambridge: MIT Press, 2016.
- RASCHKA, Sebastian; MIRJALILI, Vahid. **Python Machine Learning**. 3 ed. Birmingham: Packt, 2017.
- RUSSEL, Stuart; NORVIG, Peter. **Artificial Intelligence: A Modern Approach**. 3 ed. Upper Saddle River: Pearson, 2010.
- TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. **Introduction to Data Mining**. 2 ed. Upper Saddle River: Pearson, 2018.
- VANDERPLAS, Jake. **Python Data Science Handbook**. Sebastopol: O'Reilly, 2017.

ADICIONAIS:

- FACELI, Katti et al. **Inteligência artificial: uma abordagem de aprendizado de máquina**. 2ª Ed. Rio de Janeiro: LTC- Livros Técnicos e Científicos, 2021.
- LUGER, George F. **Inteligência Artificial** - 6ª ed. São Paulo: Pearson Education do Brasil, 2015.
- RUSSELL, Stuart; NORVIG, Peter. **Inteligência artificial: Uma Abordagem Moderna** - 4ª. Ed. GEN LTC, 2022.