

Assistente Virtual Acadêmico Baseado em RAG: Uma Abordagem Local com LLMs para Apoio ao Aprendizado

Matteo Porcare¹, Tomy Goldberg Boimel¹, Yuri Milliet¹, Lucas Tuon de Matos¹

¹Curso de Ciência da Computação – Faculdade de Computação e Informática (FCI) –
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10418276, 10417109, 10417884, 10417987}@mackenzista.com.br

Abstract. *This project describes the development of an academic virtual assistant based on Large Language Models (LLMs) and the Retrieval-Augmented Generation (RAG) architecture. The main objective is to facilitate access to information and support student learning by answering questions accurately and contextualized to the teaching materials of the Artificial Intelligence course. To mitigate the problem of hallucinations common in generic models, the system restricts its answers to the provided corpus (teacher's materials and supporting literature). The technical solution involves text extraction, embedding generation, vector indexing using the FAISS library, and the execution of a lightweight, local LLM through Ollama. User interaction occurs through a Streamlit interface. Partial results indicate the technical feasibility of building a secure, functional prototype focused on accuracy and source traceability.*

Resumo. *Este projeto descreve o desenvolvimento de um assistente virtual acadêmico baseado em Large Language Models (LLMs) e na arquitetura Retrieval-Augmented Generation (RAG). O objetivo principal é facilitar o acesso à informação e apoiar o aprendizado dos alunos, respondendo a dúvidas de forma precisa e contextualizada aos materiais didáticos da disciplina de Inteligência Artificial. Para mitigar o problema das alucinações comuns em modelos genéricos, o sistema restringe suas respostas ao corpus fornecido (materiais do professor e literatura de apoio). A solução técnica envolve a extração de textos, geração de embeddings, indexação vetorial utilizando a biblioteca FAISS e a execução de um LLM leve e local através do Ollama. A interação com o usuário ocorre por meio de uma interface em Streamlit. Resultados parciais indicam a viabilidade técnica da construção de um protótipo funcional seguro, focado em precisão e rastreabilidade das fontes.*

1. Introdução

A popularização dos *Large Language Models* (LLMs) transformou a maneira como os estudantes buscam informações e interagem com conteúdos educacionais. No entanto, o uso de modelos genéricos no contexto acadêmico apresenta um desafio significativo: as respostas muitas vezes carecem de especificidade em relação ao conteúdo ministrado em sala de aula ou geram "alucinações", caracterizadas por informações incorretas apresentadas como fatos verídicos. Nesse cenário, ferramentas que consigam aliar o processamento de linguagem natural da Inteligência Artificial (IA) com bases de conhecimento restritas e confiáveis tornam-se essenciais para o apoio pedagógico.

O desenvolvimento deste assistente virtual justifica-se pela necessidade de fornecer aos alunos respostas precisas, rápidas e estritamente fundamentadas no

material da disciplina. A escolha de utilizar LLMs com uma arquitetura de recuperação de informação, garante que a IA não invente respostas, aumentando a confiabilidade do processo. Além disso, a utilização de ferramentas de código aberto e execução local democratiza o acesso a essas tecnologias sem comprometer a privacidade dos dados.

Nesse contexto, o objetivo deste projeto é desenvolver um protótipo funcional de um assistente virtual acadêmico capaz de responder a dúvidas de alunos sobre a disciplina de Inteligência Artificial. O sistema recupera trechos relevantes do material didático fornecido e gera respostas contextualizadas, citando de forma transparente a fonte da informação. A arquitetura adotada baseia-se na construção de um pipeline RAG (*Retrieval-Augmented Generation*), priorizando o processamento de uma base restrita (PDFs, slides e listas de exercícios), o uso da biblioteca FAISS para busca vetorial por similaridade e a execução local de um modelo leve utilizando o motor Ollama. Esta abordagem foca no desenvolvimento de uma ferramenta eficiente e realista, suprimindo técnicas mais demoradas e custosas, como o *fine-tuning* de modelos. A interação com o usuário é centralizada em uma interface desenvolvida no *framework* Streamlit.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico que fundamenta a pesquisa, abordando conceitos de PLN, RAG e trabalhos relacionados. A Seção 3 detalha a metodologia de desenvolvimento, descrevendo as etapas de curadoria de dados e a implementação do pipeline computacional. A Seção 4 apresenta os resultados alcançados e a discussão sobre as evidências experimentais. Por fim, a Seção 5 expõe o cronograma de atividades futuras, seguida das referências bibliográficas

2. Referencial Teórico

A construção de um assistente virtual acadêmico baseado em recuperação de informação exige a compreensão de uma cadeia de conceitos interligados na ciência da computação e o estudo do estado da arte em aplicações educacionais.

2.1. Processamento de Linguagem Natural e LLMs

A Inteligência Artificial abrange sistemas capazes de mimetizar funções cognitivas humanas (RUSSELL; NORVIG, 2020). Dentro da IA, o Processamento de Linguagem Natural (PLN) atua dotando os computadores da capacidade de compreender, interpretar e gerar linguagem, sendo a base que permite a interação natural entre aluno e sistema. A evolução do PLN consolidou-se nos LLMs, baseados na arquitetura *Transformer* (VASWANI et al., 2017). Contudo, seu uso educacional impõe desafios devido às "alucinações" do modelo (ZHAO et al., 2023), evidenciando a necessidade de abordagens que restrinjam a geração textual a bases de conhecimento validadas por docentes, garantindo rigor factual (KASNECI et al., 2023).

2.2 Arquitetura RAG e Indexação Vetorial

Para solucionar a desatualização e as alucinações, Lewis *et al.* (2020) formalizaram a arquitetura RAG. Essa técnica adiciona uma etapa de "recuperação", onde o sistema busca a resposta em documentos confiáveis antes de instruir o LLM a formular a resposta final. Para que a recuperação seja eficiente, aplica-se o *chunking* (segmentação), dividindo documentos longos em fragmentos menores para respeitar a janela de contexto dos modelos. Esses fragmentos são convertidos em *embeddings* (vetores numéricos) e indexados em bibliotecas de alta performance, destacando-se o FAISS (*Facebook AI Similarity Search*), permitindo cálculos rápidos de similaridade semântica (JOHNSON; DOUZE; JÉGOU, 2019).

2.3 Trabalhos Relacionados

A literatura recente comprova a eficácia do RAG no ambiente acadêmico. Um estudo publicado pela MDPI (2024) descreveu a implementação de um assistente gerativo local processando PDFs de disciplinas, atingindo precisão de 86% e garantindo a privacidade dos dados. Kumar et al. (2024) demonstraram que soluções ancoradas em RAG possuem alta aceitação pelo corpo docente, por substituírem a restrição de IAs genéricas por um ambiente de tutoria controlado e protegido contra informações falsas. Adicionalmente, Liu et al. (2024) apresentaram o *CS50 Bot* da Universidade de Harvard, validando que o suporte guiado baseado em *scripts* de aula reduz a sobrecarga de monitores e agiliza a resolução de dúvidas estudantis.

3. Metodologia

O ciclo de desenvolvimento do sistema foi conduzido seguindo um fluxo de trabalho aplicado e experimental, estruturado em duas grandes fases (preparação de dados e interface de geração), visando a construção de um protótipo funcional executado inteiramente em ambiente local.

3.1 Curadoria, Preparação de Dados e Indexação

A base de conhecimento foi formada por um *corpus* restrito da disciplina de Inteligência Artificial, englobando PDFs de aulas, listas de exercícios e materiais complementares. O pipeline de preparação, desenvolvido em *Jupyter Notebook* utilizando a linguagem Python, iniciou-se com a extração textual (*parsing*) através da biblioteca PyPDF2, seguida de limpeza por expressões regulares (*re*) para remoção de hífens de quebra de linha e ruídos de cabeçalhos.

Para a segmentação (*chunking*), utilizou-se o *RecursiveCharacterTextSplitter* configurado estrategicamente com 1000 caracteres de limite e sobreposição (*overlap*) de 200 caracteres, impedindo o corte abrupto de conceitos estruturais. Cada fragmento recebeu metadados com seu respectivo arquivo de origem. Em seguida, os *chunks* foram convertidos em vetores semânticos pelo modelo multilíngue

paraphrase-multilingual-MiniLM-L12-v2 e alocados permanentemente em um índice vetorial utilizando a biblioteca FAISS.

3.2 Construção do Pipeline RAG e Validação

A segunda etapa consistiu na criação do aplicativo central (`app.py`) via *framework* Streamlit, que orquestra o processo de recuperação e geração. Quando o aluno submete uma dúvida, a interface converte o texto em vetor e executa uma busca (Top-K=3) no FAISS local. O contexto retornado, alinhado ao histórico de memória da sessão (`st.session_state`), é formatado e enviado ao modelo Llama 3.2 (executado localmente pelo motor Ollama). A geração é blindada por um *prompt* de sistema rigoroso, que obriga a IA a responder exclusivamente com base no contexto, mitigando alucinações.

4. Resultados

Os esforços metodológicos resultaram na prototipagem bem-sucedida de um assistente de estudos 100% local, em alinhamento aos princípios éticos de privacidade de dados e de combate à desinformação no ensino.

A validação experimental do sistema revelou alta eficácia no mecanismo de recuperação. Em testes qualitativos, ao ser inquirido sobre conceitos específicos ("Quais são os 3 pilares de um agente inteligente"), o motor FAISS localizou a informação precisa nos arquivos fonte correspondentes (ex:

Aula4-AgentesObjetivoseUtilidade.pdf). O modelo LLM, condicionado pelo *prompt* de controle, sintetizou o contexto recuperado sem incorrer em alucinações.

Um destaque técnico foi a implementação da geração por fluxo (*streaming*), que amenizou o gargalo do hardware local, renderizando a resposta na tela de forma contínua e que mostra que o modelo está pensando e não travado.. Adicionalmente, a implementação do módulo de auditoria visual na interface permite ao aluno visualizar o extrato bruto recuperado pelo RAG, viabilizando a rastreabilidade da resposta e garantindo a responsabilidade do sistema.



Imagem 1



O que é aprendizado de máquina e como ele serve na vida real?



O aprendizado de máquina (ou machine learning) é uma técnica de inteligência artificial que permite que os sistemas aprendam e melhorem seu desempenho através de um conjunto de dados, sem precisar ser explicitamente programados para realizar uma tarefa específica. Isso é possível graças à capacidade dos algoritmos de processamento de dados para analisar, aprender com e aplicar as informações extraídas dos dados.

O aprendizado de máquina tem várias aplicações na vida real, como:

- **Recomendação:** sistemas que sugerem produtos ou serviços de acordo com os hábitos e preferências dos usuários.
- **Previsão:** modelos que preveem tendências no mercado, como a previsão de vendas ou o crescimento do consumidor.
- **Segmentação:** análise da população para identificar características demográficas, psicográficas, comportamentais e geográficas.
- **Detecção Anomalo:** Identificação anormalidade no dados que pode ser usada em segurança, fraude detectio e outros processos.

Essas são apenas algumas das muitas formas como o aprendizado de máquina é usado atualmente na vida real.

Imagem 2



Como treinar o meu cachorro com Inteligência Artificial?



Processando a resposta...

Não possuo informações suficientes no material didático para responder a isso.

Imagem 3




Imagem 4

Interessante destacar que, na Imagem 4, o modelo respondeu qual é a capital do Brasil. E isso faz sentido, pois no livro fornecido como material didático “Inteligência Artificial e Sociedade Conectada”, essa informação é citada.

Link Github: <https://github.com/LucasTuon/AssistenteVirtualBaseadoemRAG>

Link Video Youtube: <https://youtu.be/6TEr1lzRrg4>

5. Referências

JOHNSON, J.; DOUZE, A.; JÉGOU, H. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, v. 7, n. 3, p. 535-547, 2019. Disponível em: <https://ieeexplore.ieee.org/document/8733051>. Acesso em: 27 maio 2026.

KASNECI, E. et al. ChatGPT for good? On opportunities and challenges of large language models for education. *Learning and Individual Differences*, v. 103, p. 102274, 2023. Disponível em: <https://doi.org/10.1016/j.lindif.2023.102274>. Acesso em: 27 maio 2026.

KUMAR, A. et al. Faculty Perspectives on the Potential of RAG in Computer Science Higher Education. *arXiv preprint*, arXiv:2408.01462, 2024. Disponível em: <https://arxiv.org/abs/2408.01462>. Acesso em: 27 maio 2026.

LEWIS, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: Advances in Neural Information Processing Systems (NeurIPS), v. 33, p. 9459-9474, 2020. Disponível em: <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>. Acesso em: 27 maio 2026.

LIU, R. et al. Teaching CS50 with AI: Leveraging Large Language Models for Education. In: Proceedings of the 55th ACM Technical Symposium on Computer Science Education (SIGCSE), 2024. Disponível em: <https://dl.acm.org/doi/10.1145/3626252.3634965>. Acesso em: 27 maio 2026.

MDPI. Developing a Local Generative AI Teaching Assistant System: Utilizing Retrieval-Augmented Generation Technology to Enhance the Campus Learning Environment. Electronics, v. 14, n. 17, 2024. Disponível em: <https://www.mdpi.com/2079-9292/14/17/3402>. Acesso em: 27 maio 2026.

RUSSELL, S.; NORVIG, P. Inteligência artificial: uma abordagem moderna. 4. ed. Rio de Janeiro: GEN LTC, 2022.

VASWANI, A. et al. Attention is all you need. In: Advances in Neural Information Processing Systems (NIPS), v. 30, 2017. Disponível em: <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845af-Abstract.html>. Acesso em: 27 maio 2026.

ZHAO, W. X. et al. A Survey of Large Language Models. arXiv preprint, arXiv:2303.18223, 2023. Disponível em: <https://arxiv.org/abs/2303.18223>. Acesso em: 27 maio 2026.